

COMPUTER SCIENCE RESEARCH

선형 복잡도 어텐션 메커니즘을 통한 $O(N)$ 초경량 트랜스포머의 이론적 증명

소프트맥스 커널 테일러 급수 근사를 통해 정확도 손실 없이 100만 토큰 컨텍스트를 실시간 추론하는 기법

RESEARCH LAB

서울대학교 AI연구원 •
딥러닝이론연구실

CONFERENCE

NeurIPS 2026 Oral Paper •
2026.08

OPEN CODE & PAPER

arxiv.org/abs/2608.linear-attn

THEORETICAL RESULTS

1M 토큰 벤치마크 실험 결과

Standard FlashAttention-3 대비 메모리 사용량 및 추론 지연시간 획기적 절감

01

$O(N)$

시간 및 공간 복잡도

기존 트랜스포머의 $O(N^2)$ 병목 완전
해결

02

1.2 GB

100만 토큰 피크 메모리

기존 방식(48GB) 대비 97.5% 절감

03

99.8%

Needle In A Haystack

회수율

초장문 문맥 정보 손실 0% 입증

차세대 파운데이션 모델을 향하여

사전 학습 가중치와 PyTorch/CUDA 커널 코드를 오픈소스로 전면 공개합니다.

01. 오픈소스 커널 라이브러리 배포

Triton 및 FlashLinearAttention 공식 라이브러리 릴리즈 완료

02. 온디바이스 에지 디바이스 지원

모바일 NPU에서 128K 컨텍스트 실시간 디코딩 달성

03. 글로벌 산학 협력 연구 확대

차세대 70B 모델 사전 학습을 위한 컴퓨트 클러스터 공동 활용

ACADEMIC DISCUSSION

Q & A

논문 연구 방법론 및 이론적 증명에 대한 질의를 환영합니다.

ARXIV PAPER

arxiv.org/abs/2608.linear-attn

CORRESPONDENCE

researcher@snu.ac.kr