

온디바이스 소형 언어 모델(sLLM)을 활용한 실시간 한국어 문맥 추론 및 요약 엔진

모바일 엣지 디바이스 환경에서 메모리 사용량 최적화와 추론 지연시간 단축에 관한 연구

발표자: 인공지능연구소 자연어처리팀 학술대회: 2026 AI Research Symposium 세션: Edge Intelligence

Paper No. 2026-AI-088

EXPERIMENTAL RESULTS

3대 핵심 연구 성과 및 벤치마크 검증

양자화(Quantization)와 캐시 최적화를 통해 기존 모델 대비 처리 속도 3.4배 향상

01. LATENCY REDUCTION

추론 지연시간 68% 단축

- KV 캐시 프루닝(Pruning) 기법 적용
- 첫 토큰 생성(TTFT) 42ms 달성
- 초당 38.5 토큰 실시간 스트리밍

02. MEMORY FOOTPRINT

RAM 점유율 1.8GB 유지

- 4-bit AWQ 양자화로 압축률 극대화
- 모바일 저전력 LPDDR5X 완벽 지원
- 백그라운드 메모리 누수 0% 달성

03. BENCHMARK ACCURACY

한국어 문해력 94.2점

- Ko-Harness 종합 평가 기준 준수
- 전문 도메인 용어 오역률 1.2% 미만
- 환각 현상(Hallucination) 78% 억제