

온디바이스 소형 언어 모델(sLLM)을 활용한 실시간 한국어 문맥 추론 및 요약 엔진

모바일 엣지 디바이스 환경에서 메모리 사용량 최적화와 추론 지연시간 단축에 관한 연구

AUTHORS & LAB

인공지능연구소 자연어처리팀

SYMPOSIUM & SESSION

2026 AI Symposium •
Edge Track


PAPER REGISTRATION

Paper No. 2026-AI-088

PAPER OUTLINE

CONTENTS

연구 배경부터
실험 벤치마크까지 4챕터



01

연구 배경 및 당면 과제

- 엣지 디바이스 하드웨어 제약
- 한국어 토큰나이저 메모리 오버헤드
- 저지연 스트리밍 구현 한계

02

경량화 아키텍처 설계

- 4-bit AWQ 활성화 양자화
- 동적 KV Cache Pruning 기법
- 모바일 NPU 연산 최적화 파이프라인

03

실험 결과 및 정량 분석

- Ko-Harness 벤치마크 평가
- TTFT 및 토큰 생성 속도 측정
- 전력 소모 및 RAM 점유율 비교

04

결론 및 향후 연구 방향

- 온디바이스 멀티모달 확장 방안
- 연속 학습(Continual Learning)
- 오픈소스 모델 가중치 공개 계획

EXPERIMENTAL RESULTS

3대 핵심 연구 성과 및 벤치마크 검증

양자화(Quantization)와 캐시 최적화를 통해 기존 모델 대비 처리 속도 3.4배 향상

01

추론 지연시간 68% 단축

- KV 캐시 프루닝(Pruning) 기법 적용
- 첫 토큰 생성(TTFT) 42ms 달성
- 초당 38.5 토큰 실시간 스트리밍

02

RAM 점유율 1.8GB 유지

- 4-bit AWQ 양자화로 압축률 극대화
- 모바일 저전력 LPDDR5X 완벽 지원
- 백그라운드 메모리 누수 0% 달성

03


한국어 문해력 94.2점

- Ko-Harness 종합 평가 기준 준수
- 전문 도메인 용어 오역률 1.2% 미만
- 환각 현상(Hallucination) 78% 억제

OPTIMIZATION PIPELINE

온디바이스 배포를 위한 3단계 모델 경량화 파이프라인

가중치 압축부터 캐시 압축, 하드웨어 가속기 오프로딩까지 유기적으로 연결됩니다.



ABLATION STUDY

기존 온디바이스 모델 대비 성능 비교 매트릭스

동일한 3B 파라미터 규모에서 기존 최고 성능 모델 대비 모든 지표에서 유의미한 우위 입증

✓ 추론 속도 및 반응성 (Latency & Throughput)

- 첫 토큰 생성(TTFT): 140ms → 42ms (68% 단축)
- 초당 생성 토큰 수: 11.2 → 38.5 tokens/s
- 최대 컨텍스트 길이: 8K 토큰 무손실 지원

✓ 자원 효율성 및 정확도 (Efficiency & Quality)

- 피크 메모리 사용량: 5.4GB → 1.8GB (66% 절감)
- Ko-Harness 벤치마크: 88.4점 → 94.2점 달성
- 시간당 배터리 소모율: 4.2% 수준 극저치 유지

CONCLUSION & REPO

결론 및 질의응답 (Q&A)

소형 언어 모델의 엣지 배포 가능성을 확인하였으며, 오픈소스 모델 가중치를 공개합니다.

01. 4-bit AWQ + KV 캐시 프루닝 실증

정확도 저하 없이 메모리 66% 절감 및 모바일 RAM 1.8GB 유지

02. 실시간 스트리밍 38.5 tok/s 달성

첫 토큰 지연시간 42ms로 온디바이스 실시간 UX 완벽 지원

03. 오픈 연구 생태계 기여

사전 학습된 한국어 가중치 및 양자화 파이프라인 공개

ACADEMIC DISCUSSION

Q & A

논문 연구 방법론 및 벤치마크에 대한 질의응답을 진행합니다.

OPEN RESEARCH REPO

github.com/ai-lab/edge-sllm

CORRESPONDING AUTHOR

lead-researcher@ailab.org