

CONFERENCE PAPER & RESEARCH

온디바이스 소형 언어 모델(sLLM)을 활용한 실시간 한국어 문맥 추론 및 요약 엔진

모바일 엣지 디바이스 환경에서 메모리 사용량 최적화와 추론 지연시간 단축에 관한 연구

AUTHORS & LAB

인공지능연구소 자연어처리팀

SYMPOSIUM & SESSION

2026 AI Symposium •
Edge Track

PAPER REGISTRATION

Paper No. 2026-AI-088

PAPER OUTLINE

CONTENTS

연구 배경부터
실험 벤치마크까지
4챕터

01

연구 배경 및 당면 과제

- 엣지 디바이스 하드웨어 제약
- 한국어 토큰나이저 메모리
오버헤드
- 저지연 스트리밍 구현 한계

02

경량화 아키텍처 설계

- 4-bit AWQ 활성화 양자화
- 동적 KV Cache Pruning 기법
- 모바일 NPU 연산 최적화
파이프라인

03

실험 결과 및 정량 분석

- Ko-Harness 벤치마크 평가
- TTFT 및 토큰 생성 속도 측정
- 전력 소모 및 RAM 점유율 비교

04

결론 및 향후 연구 방향

- 온디바이스 멀티모달 확장 방안
- 연속 학습(Continual Learning)
- 오픈소스 모델 가중치 공개 계획

EXPERIMENTAL RESULTS

3대 핵심 연구 성과 및 벤치마크 검증

양자화(Quantization)와 캐시 최적화를 통해 기존 모델 대비 처리 속도 3.4배 향상

01

추론 지연시간 68% 단축

- KV 캐시 프루닝(Pruning) 기법 적용
- 첫 토큰 생성(TTFT) 42ms 달성
- 초당 38.5 토큰 실시간 스트리밍

02

RAM 점유율 1.8GB 유지

- 4-bit AWQ 양자화로 압축률 극대화
- 모바일 저전력 LPDDR5X 완벽 지원
- 백그라운드 메모리 누수 0% 달성

03

한국어 문해력 94.2점

- Ko-Harness 종합 평가 기준 준수
- 전문 도메인 용어 오역률 1.2% 미만
- 환각 현상(Hallucination) 78% 억제

온디바이스 배포를 위한 3단계 모델 경량화 파이프라인

가중치 압축부터 캐시 압축, 하드웨어 가속기 오프로딩까지 유기적으로 연결됩니다.

STEP 1: AWQ

4-bit 가중치 양자화
정확도 손실 0.3% 미만



STEP 2: KV PRUNING

동적 토큰 압축
컨텍스트 메모리 60% 절감



STEP 3: NPU RUNTIME

모바일 칩셋 가속
배터리 전력 소모 55% 개선

✓ 활성화 인식 양자화 (Activation-aware Weight Quantization)

중요 가중치 채널을 보존하여 4-bit 환경에서도 한국어 문맥 추론 능력을 99% 이상 유지

✓ NPU 하드웨어 친화적 커널 퓨전 (Kernel Fusion)

메모리 I/O 병목을 제거하여 모바일 디바이스의 발열과 전력 소모를 대폭 억제

기존 온디바이스 모델 대비 성능 비교 매트릭스

동일한 3B 파라미터 규모에서 기존 최고 성능 모델 대비 모든 지표에서 유의미한 우위 입증

✓ 추론 속도 및 반응성 (Latency & Throughput)

- 첫 토큰 생성(TTFT): **140ms → 42ms (68% 개선)**
- 초당 생성 토큰 수: **11.2 tokens/s → 38.5 tokens/s**
- 최대 컨텍스트 길이: **8K 토큰 무손실 지원**

✓ 자원 효율성 및 정확도 (Efficiency & Quality)

- 피크 메모리 사용량: **5.4GB → 1.8GB (66% 절감)**
- Ko-Harness 벤치마크: **88.4점 → 94.2점 달성**
- 시간당 배터리 소모율: **4.2% 수준으로 극저치 기록**

결론 및 질의응답 (Q&A)

소형 언어 모델의 엣지 배포 가능성을 확인하였으며, 오픈소스 모델 가중치를 공개합니다.

01. 4-bit AWQ + KV 캐시 프루닝 실증
정확도 저하 없이 메모리 66% 절감 및 모바일 RAM
1.8GB 유지

02. 실시간 스트리밍 38.5 tok/s 달성
첫 토큰 지연시간 42ms로 온디바이스 실시간 UX
완벽 지원

03. 오픈 연구 생태계 기여
사전 학습된 한국어 가중치 및 양자화 파이프라인 공개

ACADEMIC DISCUSSION

Q & A

논문 연구 방법론 및 벤치마크에 대한 질의응답을
진행합니다.

OPEN RESEARCH REPO

github.com/ai-lab/edge-sllm

CORRESPONDING AUTHOR

lead-researcher@ailab.org